Detecção de Discurso de ódio e toxicidade conversacional com GNN em Plataformas de Redes Sociais

Carlos Eduardo Hayashi[1]. Edson Luiz Cardoso Ohira[1,2,] Vinicius Oliveira Piccazzio[1,3]

[1]Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

[2]Inteligencia Artificial – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10419790, 10419663, 10419471}@mackenzista.com.br

Resumo: *O projeto propõe o desenvolvimento de modelos fundamentados em Redes Neurais Gráficas (GNNs) para detecção automatizada de discurso de ódio em redes sociais, considerando tanto o conteúdo das mensagens quanto o contexto das interações entre usuários. A pesquisa busca promover ambientes digitais mais seguros e avançar o estado da arte em PLN e aprendizado profundo. A metodologia inclui revisão bibliográfica, construção de bases de dados, pré-processamento textual, modelagem de grafos e treinamento de modelos GCN e GAT. Espera-se criar um protótipo funcional com maior precisão e robustez que os métodos tradicionais, além de realizar análises comparativas e de interpretabilidade, contribuindo para o desenvolvimento ético e transparente da Inteligência Artificial.*

Palavras-chave: *Discurso de ódio; Toxicidade conversacional; Moderação de conteúdo; Redes neurais gráficas (GNN); Processamento de Linguagem Natural; Redes sociais.*

1. Introdução

1.1 Contextualização

O avanço das tecnologias digitais e a popularização das redes sociais transformaram profundamente a forma como indivíduos interagem e compartilham informações. Contudo, esse crescimento também favoreceu a propagação de conteúdos ofensivos, incluindo discurso de ódio, assédio e toxicidade conversacional. Esses fenômenos têm impactos sociais e psicológicos relevantes, afetando tanto indivíduos quanto comunidades inteiras (AL-SAQQA; AWAJAN; HAMMO, 2024; DAS et al., 2024).

Nesse cenário, a utilização de técnicas de Inteligência Artificial, especialmente no campo do Processamento de Linguagem Natural (PLN), tem se mostrado fundamental para a automação da moderação de conteúdo (DEVLIN et al., 2019; LIU et al., 2019). Entretanto, muitos dos métodos existentes ainda apresentam limitações, principalmente por analisarem mensagens de forma isolada, sem considerar o contexto das interações (NOURI; COINTET; CLAVEL, 2025).

1.2 Justificativa

A crescente exposição de usuários a conteúdos tóxicos e abusivos nas redes sociais representa um desafio ético, social e tecnológico. Tais manifestações comprometem a qualidade dos ambientes digitais, intensificam conflitos e podem gerar impactos psicológicos relevantes (ABUSAQER; SAQUER; SHATNAWI, 2025; PAUL; BORA, 2021). Assim, desenvolver métodos computacionais capazes de identificar e mitigar esses comportamentos é essencial para promover espaços online mais seguros e inclusivos.

Do ponto de vista científico, a aplicação de Graph Neural Networks (GNNs) na detecção de discurso de ódio constitui um avanço importante para o Processamento de Linguagem Natural (PLN), ao permitir a análise de relações contextuais e estruturais entre mensagens e usuários (KIPF; WELLING, 2017; VÉLIČKOVIĆ et al., 2018). Além disso, a pesquisa contribui para o campo de Sistemas de Informação, ao integrar aspectos técnicos e éticos da Inteligência Artificial, favorecendo a construção de soluções transparentes, explicáveis e socialmente responsáveis (NIRMAL et al., 2024; FETAHI et al., 2025).

1.3 Objetivo Geral

Investigar e apresentar um modelo baseado em Redes Neurais Gráficas (GNNs) para a detecção de discurso de ódio e toxicidade em redes sociais, considerando o contexto conversacional e as relações entre usuários, de modo a superar as limitações dos métodos tradicionais e contribuir para a criação de ambientes digitais mais seguros. Tal abordagem baseia-se em avanços recentes que demonstram a eficácia da integração entre representações linguísticas e estruturais na análise de interações sociais (DUONG; ZHANG; LU, 2022; ROSSI et al., 2020).

1.4 Opção do Projeto

O presente trabalho caracteriza-se como um projeto de natureza experimental e aplicada, inserido no contexto da Inteligência Artificial e do aprendizado profundo, com foco na resolução de problemas reais relacionados à moderação automatizada de conteúdo em plataformas digitais. A proposta fundamenta-se na utilização de modelos de linguagem pré-treinados e arquiteturas baseadas em grafos, que têm se destacado como abordagens eficazes para lidar com a complexidade das interações em redes sociais (HEBERT et al., 2023; BROOK; MARKOV, 2025).

2. Fundamentação Teórica

2.1 Conceitos Fundamentais

O projeto fundamenta-se em conceitos centrais da Inteligência Artificial, com destaque para o Processamento de Linguagem Natural (PLN), o Aprendizado Profundo (Deep Learning) e as Redes Neurais Gráficas (GNNs). O PLN é responsável pela análise e interpretação da linguagem humana por sistemas computacionais, incluindo o uso de técnicas modernas baseadas em modelos pré-treinados, como BERTimbau, que permitem capturar o contexto semântico das palavras em diferentes situações (DEVLIN et al., 2019; LIU et al., 2019).

O aprendizado profundo, por sua vez, utiliza redes neurais artificiais para modelar padrões complexos em grandes volumes de dados, sendo essencial para tarefas de classificação e representação de linguagem (MIKOLOV et al., 2013). Já as Redes Neurais Gráficas possibilitam a operação sobre estruturas em grafos, permitindo modelar relações entre diferentes entidades, como usuários e mensagens em redes sociais (KIPF; WELLING, 2017; VÉLIČKOVIĆ et al., 2018).

A integração dessas abordagens proporciona uma solução mais robusta, capaz de analisar simultaneamente o conteúdo textual e a estrutura das interações, contribuindo para uma detecção mais eficaz de padrões de toxicidade e discurso de ódio (MAJEED; RAUF, 2020;).

2.2 Trabalhos Relacionados

A literatura recente apresenta avanços significativos na detecção automática de discurso de ódio. Modelos baseados em aprendizado profundo, como BERTimbau, demonstraram melhorias substanciais na compreensão contextual da linguagem (DEVLIN et al., 2019; ABUSAQER; SAQUER; SHATNAWI, 2025).

Entretanto, estudos mais recentes evidenciam que a incorporação de relações estruturais, por meio de grafos, pode aumentar significativamente a eficácia dos modelos. Arquiteturas como HateNet, baseadas em GNNs, têm demonstrado resultados superiores ao considerar interações entre mensagens (DUONG; ZHANG; LU, 2022; BÖLÜCÜ; CANBAY, 2021).

Além disso, abordagens multimodais e métodos explicáveis vêm sendo explorados para aumentar a transparência e a robustez dos sistemas, reforçando a importância da integração entre diferentes técnicas no desenvolvimento de soluções mais eficazes (NIRMAL et al., 2024; HEBERT et al., 2023).

3. Metodologia e Resultados Esperados

3.1 Tipo de Pesquisa

O projeto adota uma abordagem baseada na integração entre técnicas de Processamento de Linguagem Natural (PLN) e Redes Neurais Gráficas (GNNs), com o objetivo de detectar

discurso de ódio considerando tanto o conteúdo textual quanto o contexto das interações (KIPF; WELLING, 2017; VÉLIČKOVIĆ et al., 2018).

Inicialmente, será realizada a coleta e organização dos dados, seguida pelo pré-processamento textual, incluindo limpeza, normalização e tokenização. Em seguida, as interações serão modeladas em forma de grafos, onde mensagens são representadas como nós e suas relações como arestas (ROSSI et al., 2020). Paralelamente, serão gerados embeddings textuais por meio de modelos pré-treinados (DEVLIN et al., 2019).

Na etapa seguinte, será implementado um modelo baseline baseado apenas em texto, seguido pelo desenvolvimento do modelo principal utilizando GNNs. Por fim, os modelos serão avaliados com base em métricas como precision, recall e F1-score.

Como resultado esperado, pretende-se obter um modelo mais robusto e preciso do que abordagens tradicionais, especialmente na identificação de padrões de toxicidade em contextos conversacionais (NOURI; COINTET; CLAVEL, 2025).

3.2 Dataset, análise exploratória e preparação dos dados

O projeto utiliza um dataset composto por mensagens provenientes de redes sociais, contendo informações sensíveis e confidenciais. Em razão disso, foi necessário adotar cuidados específicos relacionados à privacidade, incluindo o tratamento adequado dos dados e a anonimização de informações que possam identificar usuários (BISWAS et al.; FETAHI et al., 2025).

Adicionalmente, os dados utilizados não possuíam rotulação prévia, sendo necessário realizar o processo de anotação manual das mensagens, classificando-as conforme a presença ou ausência de discurso de ódio. Essa etapa exigiu critérios bem definidos para garantir maior consistência e qualidade na rotulação, conforme práticas adotadas na literatura (PAUL; BORA, 2021).

A análise exploratória dos dados foi conduzida com o objetivo de compreender a distribuição das classes, identificar possíveis desbalanceamentos e analisar padrões linguísticos relevantes. Já a preparação dos dados envolveu etapas de limpeza textual, normalização, tokenização e geração de embeddings (MIKOLOV et al., 2013).

Por fim, será realizada a construção de grafos representando as interações entre mensagens, permitindo incorporar o contexto conversacional ao modelo e enriquecer a representação dos dados (MAJEED; RAUF, 2020).

4. Resultados Parciais

4.1 Aspectos éticos e responsabilidade no uso da IA

O uso de Inteligência Artificial na moderação de conteúdo envolve desafios éticos, como viés algorítmico, decisões incorretas e impactos sociais. Dessa forma, o projeto considera aspectos de responsabilidade, incluindo a análise de vieses, a transparência dos modelos e o tratamento adequado de dados sensíveis.

4.2 Resultados parciais obtidos

Até o momento, foram alcançados resultados importantes para o desenvolvimento do projeto, incluindo a definição do problema de pesquisa e dos objetivos propostos, a realização de uma revisão bibliográfica inicial, bem como a seleção e organização dos datasets a serem utilizados. Adicionalmente, foi realizada a etapa de limpeza dos dados, juntamente com a estruturação do pipeline de pré-processamento. Também foi definido o planejamento da arquitetura do modelo.

4.3 Repositório GitHub

O projeto possui um repositório no GitHub para organização e versionamento do desenvolvimento:

https://github.com/Piccazzio/Projeto_IA/tree/main

O repositório inclui documentação do projeto e scripts utilizados para a limpeza dos dados.

5. Referências

ABUSAQER, Mahmoud; SAQUER, Jamil; SHATNAWI, Hazim. Efficient Hate Speech Detection: Evaluating 38 Models from Traditional Methods to Transformers. arXiv preprint arXiv:2509.14266, 2025. Disponivel em: https://arxiv.org/pdf/2509.14266 . Acesso em: 01 abril 2026.

AL-SAQQA, Samar; AWAJAN, Arafat; HAMMO, Bassam. A Survey of Hate Speech Detection for Arabic Social Media: Methods and Datasets. Procedia Computer Science, v. 251, p. 224–231, 2024. DOI: 10.1016/j.procs.2024.11.104. Disponível em: https://www.sciencedirect.com/science/article/pii/S1877050924033386 . Acesso em: 01 abril 2026.

BISWAS, Md. Rafiul; ALAM, Firoj; ZAGHOUANI, Wajdi. MARSAD: A Multi-Functional Tool for Real-Time Social Media Analysis. 2025. arXiv:2512.01369 [cs.CL]. Disponível em: https://arxiv.org/pdf/2512.01369 . Acesso em: 01 abril 2026.

BÖLÜCÜ, Necva; CANBAY, Pelin. Hate Speech and Offensive Content Identification with Graph Convolutional Networks (HASOC). CEUR Workshop Proceedings, v. 3159, 2021. Disponível em: https://ceur-ws.org/Vol-3159/T1-4.pdf . Acesso em: 01 abril 2026.

BROOK, Joshua Wolfe; MARKOV, Ilia. Leveraging LLMs for Context-Aware Implicit Textual and Multimodal Hate Speech Detection. 2025. arXiv:2510.15685 [cs.CL]. Disponível em: https://arxiv.org/pdf/2510.15685 . Acesso em: 01 abril 2026.

DAS, Susmita; DUTTA, Arpita; ROY, Kingshuk; MONDAL, Abir; MUKHOPADHYAY, Arnab. A Survey on Automatic Online Hate Speech Detection in Low-Resource Languages. arXiv preprint, 2024. Disponível em: https://arxiv.org/abs/2411.19017 . Acesso em: 01 abril 2026.

DEVLIN, Jacob; CHANG, Ming-Wei; LEE, Kenton; TOUTANOVA, Kristina. BERT: Pretraining of Deep Bidirectional Transformers for Language Understanding. Proceedings of NAACL-HLT 2019, p. 4171–4186, 2019. Disponível em: https://aclanthology.org/N19-1423/ . Acesso em: 01 abril 2026.

DUONG, Charles; ZHANG, Lei; LU, Chang-Tien. HateNet: A Graph Convolutional Network Approach to Hate Speech Detection. IEEE BigData Workshops, 2022. Disponível em: https://people.cs.vt.edu/~clu/Publication/2022/IEEE-BD22-Proceedings-Duong.pdf . Acesso em: 01 abril 2026.

FETAHI, Endrit; SUSURI, Arsim; HAMITI, Mentor; KASTRATI, Zenun; CANHASI, Ercan; MISINI, Arta. Enhancing Social Media Hate Speech Detection in Low-Resource Languages using transformers and explainable AI. Social Network Analysis and Mining, 2025. Disponível em: https://link.springer.com/article/10.1007/s13278-025-01497-w . Acesso em: 01 abril 2026.

HEBERT, Liam; CHEN, Hong Yi; COHEN, Robin; GOLAB, Łukasz. Qualitative Analysis of a Graph Transformer Approach to Addressing Hate Speech: Adapting to Dynamically Changing Content. 2023a. arXiv:2301.10871 [cs.LG]. Disponível em: https://arxiv.org/pdf/2301.10871 . Acesso em: 01 abril 2026.

HOQUE, Syed Mohaiminul; RAHMAN, Naimur; HOSSAIN, Md Sakhawat. Gradient Masters at BLP-2025 Task 1: Advancing Low-Resource NLP for Bengali using Ensemble-Based Adversarial Training for Hate Speech Detection. 2025. arXiv:2511.18324 [cs.CL]. Disponível em: https://arxiv.org/pdf/2511.18324 . Acesso em: 01 abril 2026.

KIPF, Thomas N.; WELLING, Max. Semi-Supervised Classification with Graph Convolutional Networks. International Conference on Learning Representations (ICLR), 2017. Disponível em: https://arxiv.org/abs/1609.02907. Acesso em: 01 abril 2026.

LIU, Yinhan; OTT, Myle; GOYAL, Naman; DU, Jingfei; JOSHI, Mandar; CHEN, Danqi; LEVY, Omer; LEWIS, Mike; ZETTLEMOYER, Luke; STOYANOV, Veselin. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv preprint, arXiv:1907.11692, 2019. Disponível em: https://arxiv.org/abs/1907.11692 . Acesso em: 01 abril 2026.

MAJEED, Abdul; RAUF, Ibtisam. Graph theory: A comprehensive survey about graph theory applications in computer science and social networks. Inventions, v. 5, n. 1, p. 10, 2020. Disponível em: https://www.mdpi.com/2411-5134/5/1/10 . Acesso em: 01 abril 2026.

MIKOLOV, Tomas; CHEN, Kai; CORRADO, Greg; DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. arXiv preprint, arXiv:1301.3781, 2013. Disponível em: https://arxiv.org/abs/1301.3781 . Acesso em: 01 abril 2026.

NIRMAL, Ayushi; BHATTACHARJEE, Amrita; SHETH, Paras; LIU, Huan. Towards Interpretable Hate Speech Detection using Large Language Model-extracted Rationales. arXiv preprint, 2024. Disponível em: https://arxiv.org/pdf/2403.12403 . Acesso em: 01 abril 2026.

NOURI, Célia; COINTET, Jean-Philippe; CLAVEL, Chloé. Graphically Speaking: Unmasking Abuse in Social Media with Conversation Insights. ACL 2025. Disponível em: https://aclanthology.org/2025.acl-long.894.pdf . Acesso em: 01 abril 2026.

PAUL, Chayan; BORA, Pronami. Detecting Hate Speech using Deep Learning Techniques. International Journal of Advanced Computer Science and Applications, v. 12, n. 2, p. 619-622, 2021. Disponível em: https://thesai.org/Downloads/Volume12No2/Paper_78-Detecting_Hate_Speech_using_Deep_Learning_Techniques.pdf . Acesso em: 01 abril 2026.

ROSSI, Emanuele; CHAMBERLAIN, Ben; FRASCA, Fabrizio; EYNARD, Davide; MONTI, Federico; BRONSTAIN, Michael. Temporal Graph Networks for Deep Learning on Dynamic Graphs. arXiv preprint, arXiv:2006.10637, 2020. Disponível em:

https://arxiv.org/abs/2006.10637 . Acesso em: 01 abril 2026.

VÉLIČKOVIĆ, Petar; CUCURULL, Guillem; CASANOVA, Arantxa; ROMERO, Adriana; LIÒ, Pietro; BENGIO, Yoshua. Graph Attention Networks. International Conference on Learning Representations (ICLR), 2018. Disponível em: https://arxiv.org/abs/1710.10903 . Acesso em: 01 abril 2026.