

## Detecção de Discurso de ódio e toxicidade conversacional com GNN em Plataformas de Redes Sociais

Carlos Eduardo Hayashi<sup>1</sup>. Edson Luiz Cardoso Ohira<sup>1</sup>. Vinicius Oliveira Piccazzio<sup>1</sup>

<sup>1</sup>Faculdade de Computação e Informática (FCI)  
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<sup>2</sup>Inteligencia Artificial – Faculdade de Computação e Informática (FCI) – Universidade  
Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10419790, 10419663, 10419471}@mackenzista.com.br

**Resumo:** O projeto propõe o desenvolvimento de modelos fundamentados em Redes Neurais Gráficas (GNNs) para detecção automatizada de discurso de ódio em redes sociais, considerando tanto o conteúdo das mensagens quanto o contexto das interações entre usuários. A pesquisa busca promover ambientes digitais mais seguros e avançar o estado da arte em Processamento de Linguagem Natural (PLN) e aprendizado profundo. A metodologia inclui revisão bibliográfica, construção de bases de dados, préprocessamento textual, modelagem de grafos e prevê o treinamento de modelos como Redes Convolucionais em Grafos (GCN) e Redes de Atenção em Grafos (GAT). Espera-se criar um protótipo funcional com maior precisão e robustez que os métodos tradicionais, além de realizar análises comparativas e de interpretabilidade, contribuindo para o desenvolvimento ético e transparente da Inteligência Artificial.

**Palavras-chave:** Discurso de ódio; Detecção de toxicidade; Processamento de Linguagem Natural; Redes Neurais Gráficas; Grafos; Redes sociais.

## 1. Introdução

O avanço das tecnologias digitais e a popularização das redes sociais têm transformado significativamente a forma como as pessoas se comunicam, compartilham informações e interagem em ambientes virtuais. Entretanto, esse crescimento também trouxe desafios relevantes, como o aumento da disseminação de conteúdos ofensivos, abusivos e de discurso de ódio (AL-SAQQA; AWAJAN; HAMMO, 2024). Esse tipo de conteúdo pode gerar impactos negativos tanto em nível individual quanto coletivo, afetando a saúde mental dos usuários, promovendo a desinformação e intensificando conflitos sociais (DAS et al., 2024), o que torna sua identificação e controle uma questão de grande relevância para a sociedade contemporânea e para a área de tecnologia.

Nesse contexto, a detecção automática de discurso de ódio tem sido amplamente estudada no campo do PLN. Com o avanço do aprendizado profundo, modelos baseados em redes neurais passaram a apresentar desempenho superior em tarefas de classificação textual (ABUSAQER; SAQUER; SHATNAWI, 2025). Em especial, arquiteturas baseadas em Transformers, como o BERT, introduzido por Devlin et al. (2019), têm se destacado por sua capacidade de compreender o contexto das palavras de forma bidirecional, capturando relações semânticas complexas e melhorando significativamente a performance em diversas aplicações de PLN.

Apesar dos avanços obtidos com modelos puramente textuais, muitas abordagens ainda consideram os dados de forma isolada, desconsiderando as relações existentes entre diferentes conteúdos. Em ambientes digitais, especialmente nas redes sociais, as mensagens estão frequentemente conectadas por meio de interações entre usuários, similaridade semântica ou contexto conversacional (NOURI; COINTET; CLAVEL, 2025). Nesse cenário, técnicas baseadas em grafos têm ganhado destaque, pois permitem representar essas relações de forma estruturada. As GNNs surgem como uma abordagem promissora, sendo capazes de explorar dependências entre dados conectados e melhorar o desempenho em tarefas complexas (DUONG; ZHANG; LU, 2022).

Diante disso, este trabalho propõe a investigação de uma abordagem que combina modelos de linguagem com estruturas baseadas em grafos para a detecção de discurso de ódio. Para isso, foi utilizado um dataset com dados sigilosos cedido pelo CIBERDEM, contendo dados relacionados aos eventos da invasão dos Três Poderes em 08 de janeiro de 2023. Inicialmente, é desenvolvido um modelo baseline utilizando o BERTimbau para classificação binária dos textos. Em seguida, são geradas representações vetoriais (embeddings), que permitem a construção de grafos baseados na similaridade semântica entre os textos. Essa estratégia possibilita explorar não apenas o conteúdo textual, mas também as relações entre os dados, abordagem que tem sido explorada em estudos recentes (HEBERT et al., 2023a). O restante deste trabalho está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica e os trabalhos relacionados; a Seção 3 descreve a metodologia adotada; a Seção 4 apresenta os resultados obtidos e a discussão ética; e, por fim, a Seção 5 apresenta as conclusões e perspectivas futuras.

## **2. Fundamentação Teórica**

### **2.1 Conceitos Fundamentais**

O projeto fundamenta-se em conceitos centrais da Inteligência Artificial, com destaque para o Processamento de Linguagem Natural (PLN), o Aprendizado Profundo (Deep Learning), a representação vetorial de textos e as Redes Neurais Gráficas (GNNs). O PLN é uma área da Inteligência Artificial voltada ao desenvolvimento de técnicas capazes de permitir que sistemas computacionais compreendam e processem a linguagem humana, sendo amplamente aplicado em tarefas como classificação textual, análise de sentimentos e detecção de conteúdos ofensivos (DAS et al., 2024). Com o avanço do aprendizado profundo, modelos baseados em Transformers, como o BERT, passaram a apresentar desempenho superior em tarefas de PLN por sua capacidade de compreender o contexto das palavras de forma bidirecional (DEVLIN et al., 2019). Além disso, modelos derivados, como o RoBERTa e o BERTimbau, apresentam melhorias voltadas à robustez e adaptação linguística, especialmente para o idioma português (LIU et al., 2019).

O aprendizado profundo utiliza redes neurais artificiais capazes de identificar padrões complexos em grandes volumes de dados, sendo fundamental para tarefas modernas de PLN. Nesse contexto, os textos são transformados em representações vetoriais conhecidas como embeddings, que permitem representar semanticamente palavras e sentenças em espaços vetoriais de alta dimensionalidade. Técnicas como o Word2Vec, proposto por Mikolov et al. (2013), contribuíram significativamente para o avanço dessas representações, enquanto modelos mais recentes baseados em Transformers passaram a gerar embeddings contextualizados, capazes de representar o significado das palavras de acordo com o contexto em que estão inseridas. Em tarefas de detecção de discurso de ódio, essas representações auxiliam na identificação de padrões linguísticos complexos, incluindo ambiguidades, ironias e dependências contextuais (AL-SAQQA; AWAJAN; HAMMO, 2024).

Além da análise textual, este trabalho também utiliza estruturas em grafos para modelar relações entre os dados. Grafos são estruturas compostas por nós e arestas, amplamente empregadas na representação de sistemas complexos e interconectados (MAJEED; RAUF, 2020). Neste projeto, cada texto é representado como um nó, enquanto as conexões entre os nós são definidas com base na similaridade semântica entre os embeddings gerados pelos modelos de linguagem. Para isso, são utilizadas técnicas como similaridade cosseno e métodos baseados em k-Nearest Neighbors (kNN), permitindo a construção de grafos mais estruturados e semanticamente relevantes. Essa abordagem possibilita identificar relações implícitas entre diferentes mensagens e explorar padrões estruturais presentes nos dados (ROSSI et al., 2020).

Nesse contexto, destacam-se as Redes Neurais Gráficas (GNNs), uma classe de modelos de aprendizado profundo projetada para operar diretamente sobre dados estruturados em grafos. Diferentemente dos modelos tradicionais, as GNNs exploram relações entre os nós por meio da propagação de informações ao longo das conexões do grafo. Entre as principais arquiteturas estão as Graph Convolutional Networks (GCN), propostas por Kipf e Welling (2017), e as Graph Attention Networks (GAT), desenvolvidas por Veličković et al. (2018), que utilizam mecanismos de atenção para atribuir diferentes pesos às conexões entre os nós. Essas abordagens têm apresentado resultados promissores na detecção de discurso de ódio e conteúdo ofensivo, especialmente por integrarem simultaneamente informações textuais e estruturais (BÖLÜCÜ; CANBAY, 2021). Dessa forma, a combinação entre PLN, embeddings contextualizados, grafos e GNNs proporciona uma abordagem mais robusta e contextualizada para a identificação de padrões de toxicidade em ambientes digitais (WASI, 2024).

## **2.2 Trabalhos Relacionados**

A detecção automática de discurso de ódio tem sido amplamente estudada, especialmente com o crescimento das redes sociais e da produção de conteúdo digital. Inicialmente, foram utilizadas abordagens baseadas em aprendizado de máquina tradicional, como Support Vector Machines (SVM) e Naive Bayes, combinadas com representações textuais como Bag-of-Words e TF-IDF. No entanto, essas técnicas apresentam limitações na captura de contexto e significado das palavras, o que motivou o desenvolvimento de métodos mais avançados.

Com o avanço do aprendizado profundo, modelos baseados em redes neurais passaram a apresentar melhores resultados em tarefas de classificação textual. Nesse cenário, o modelo BERT, que utiliza a arquitetura Transformer para compreender o contexto das palavras de forma bidirecional, permite capturar relações semânticas mais complexas.

Estudos recentes indicam que modelos baseados em Transformers apresentam desempenho superior na detecção de discurso de ódio quando comparados a métodos tradicionais, além de possibilitarem avanços em tarefas mais complexas envolvendo linguagem natural (BROOK; MARKOV, 2025). Nesse contexto, estratégias como aprendizado adversarial e modelos em conjunto (ensemble) também têm sido exploradas para melhorar a robustez desses sistemas em cenários desafiadores (HOQUE; RAHMAN; ROSSAIN, 2025). Além disso, abordagens recentes com grandes modelos de linguagem (LLMs) e estratégias multimodais têm sido exploradas para integrar diferentes tipos de informação, como texto e emoção, ampliando a capacidade de detecção de conteúdos ofensivos em cenários mais complexos.

Mais recentemente, pesquisas têm explorado o uso de GNNs, que permitem modelar relações entre dados por meio de grafos. Essas abordagens consideram não apenas o conteúdo textual, mas também as conexões entre os dados, como interações entre usuários ou similaridade entre textos. Trabalhos demonstram que a utilização de GNNs pode melhorar o desempenho na detecção de discurso de ódio ao incorporar informações estruturais, enquanto outras abordagens investigam o uso de grafos para análise contextual de conversações online.

Nesse contexto, abordagens híbridas que combinam modelos de linguagem e grafos têm se mostrado promissoras, utilizando embeddings como atributos dos nós para explorar tanto o conteúdo quanto as relações entre os dados. O presente trabalho segue essa linha ao empregar grafos baseados em similaridade semântica para aprimorar a detecção de discurso de ódio. Além disso, pesquisas recentes têm investigado a interpretabilidade em modelos de hate speech por meio de raciocínios gerados por LLMs, buscando maior transparência nas decisões (NIRMAL et al., 2024).

### **3. Metodologia e Resultados Esperados**

#### **3.1 Tipo de Pesquisa**

O projeto adota uma abordagem baseada na integração entre técnicas de Processamento de Linguagem Natural (PLN) e Redes Neurais Gráficas (GNNs), com o objetivo de detectar discurso de ódio considerando simultaneamente o conteúdo textual e as relações semânticas existentes entre as mensagens (KIPF; WELLING, 2017; VÉLIČKOVIĆ et al., 2018). Inicialmente, foi realizada a coleta e organização dos dados, seguida pela etapa de pré-processamento textual, que incluiu remoção de duplicatas, exclusão de menções a usuários, hashtags, URLs e emojis, além de procedimentos de normalização e padronização dos textos. Essas etapas são fundamentais para reduzir ruídos presentes em dados provenientes de redes sociais e melhorar a qualidade das informações utilizadas durante o treinamento dos modelos (FETAHI et al., 2025).

Em seguida, foi conduzida uma análise exploratória dos dados com o objetivo de compreender as características do dataset, incluindo a distribuição das classes, o tamanho médio dos textos e a identificação de padrões linguísticos relevantes. Essa etapa permitiu verificar possíveis desbalanceamentos entre as classes “ódio” e “não ódio”, aspecto importante em tarefas de classificação textual e detecção de discurso de ódio (ABUSAQER; SAQUER; SHATNAWI, 2025). Paralelamente, foi implementado um modelo baseline utilizando o BERTimbau, baseado na arquitetura Transformer e adaptado para o idioma português. Os textos foram tokenizados e preparados utilizando técnicas de

padding e truncamento, sendo posteriormente divididos em conjuntos de treino, validação e teste. A avaliação do modelo foi realizada por meio de métricas como precisão, recall e F1-score, amplamente utilizadas em tarefas de classificação textual (DEVLIN et al., 2019).

Após a modelagem textual, foram gerados embeddings para cada texto utilizando o modelo BERTimbau. Esses embeddings correspondem a representações vetoriais de alta dimensionalidade capazes de capturar relações semânticas e contextuais entre as mensagens. Com base nessas representações, foram construídas estruturas em grafos nas quais cada texto é representado como um nó e as conexões entre os nós são estabelecidas de acordo com a similaridade semântica entre os embeddings. Para isso, foram utilizadas abordagens baseadas em limiar de similaridade cosseno e no método k-Nearest Neighbors (kNN), permitindo a construção de grafos mais estruturados e semanticamente relevantes (LI et al., 2023). Após essa etapa, os grafos passaram por processos de refinamento, incluindo remoção de nós isolados e extração do maior componente conexo, visando melhorar a qualidade estrutural dos dados e sua adequação para aplicações com GNNs.

Por fim, os grafos serão convertidos para um formato compatível com a biblioteca PyTorch Geometric, permitindo a implementação de modelos baseados em Redes Neurais Gráficas, como Graph Convolutional Networks (GCN) e Graph Attention Networks (GAT). Nessas arquiteturas, os embeddings serão utilizados como atributos dos nós, enquanto as conexões semânticas serão representadas pelas arestas do grafo. A principal vantagem dessa abordagem consiste na capacidade de integrar simultaneamente informações textuais e estruturais, permitindo explorar relações contextuais entre diferentes mensagens e identificar padrões de toxicidade que podem não ser capturados por modelos tradicionais. Como resultado esperado, pretende-se obter um modelo mais robusto e preciso para detecção de discurso de ódio em redes sociais, contribuindo para uma análise mais contextualizada e eficiente de conteúdos ofensivos em ambientes digitais (NOURI; COINTET; CLAVEL, 2025).

### **3.2 Dataset, análise exploratória e preparação dos dados**

O conjunto de dados utilizado neste trabalho é composto por textos provenientes de uma base com informações sensíveis, cedida pelo CIBERDEM e relacionada aos eventos da invasão dos Três Poderes em 08 de janeiro de 2023. Inicialmente, a base não possuía rótulos, sendo necessário realizar um processo de rotulação manual antes da aplicação do modelo BERTimbau, prática comum em tarefas de detecção de discurso de ódio devido à complexidade e subjetividade desse tipo de conteúdo (AL-SAQQA; AWAJAN; HAMMO, 2024). Para esta etapa, foram selecionados 1.560 textos da base de dados, posteriormente divididos em três partes iguais, de modo que cada integrante do grupo ficou responsável pela anotação de uma parcela dos dados.

A rotulação foi realizada para a identificação de discurso de ódio, classificando cada texto nas categorias “ódio” ou “não ódio” a partir de aspectos semânticos e contextuais. A importância da análise contextual nesse processo é amplamente discutida na literatura, uma vez que o significado de uma mensagem pode variar de acordo com o contexto em que está inserida (XENOS et al., 2022). Além disso, será realizada uma nova rodada de anotação utilizando a estatística Kappa, com o objetivo de avaliar a concordância entre os anotadores e gerar uma base de dados mais consistente para o treinamento de um novo modelo.

## 4. Resultados

### 4.1 Aspectos éticos e responsabilidade no uso da IA

A utilização de Inteligência Artificial em sistemas de moderação de conteúdo envolve importantes desafios éticos e sociais, especialmente em tarefas relacionadas à detecção de discurso de ódio e toxicidade em ambientes digitais. Modelos de aprendizado de máquina podem apresentar vieses algorítmicos decorrentes dos dados utilizados durante o treinamento, resultando em classificações incorretas, discriminação de determinados grupos ou interpretações equivocadas de conteúdos sensíveis. Além disso, erros de classificação podem impactar diretamente a liberdade de expressão e a experiência dos usuários nas plataformas digitais (AL-SAQQA; AWAJAN; HAMMO, 2024).

Diante disso, este trabalho considera aspectos fundamentais de responsabilidade no desenvolvimento da solução proposta, incluindo a análise de possíveis vieses presentes nos dados, a busca por maior transparência e interpretabilidade dos modelos e o tratamento adequado de informações sensíveis. Também são consideradas questões relacionadas à privacidade e anonimização dos dados utilizados, visando garantir maior segurança e conformidade ética durante o desenvolvimento da pesquisa. Nesse contexto, busca-se desenvolver uma abordagem mais robusta, transparente e socialmente responsável para aplicações de Inteligência Artificial voltadas à moderação automática de conteúdo.

### 4.2 Resultados obtidos

Os resultados obtidos demonstram avanços relevantes no desenvolvimento da proposta, especialmente nas etapas de modelagem textual e construção das estruturas em grafos. A análise exploratória dos dados evidenciou um desbalanceamento entre as classes “ódio” e “não ódio”, aspecto que impacta diretamente a capacidade de identificação de conteúdos ofensivos, conforme apresentado na Figura 1. Ainda assim, o modelo baseline baseado no BERTimbau alcançou acurácia de 83% no conjunto de teste, apresentando melhor desempenho na classe “não ódio”, com precisão de 0,87 e F1-score de 0,90. Para a classe “ódio”, foram obtidos precisão de 0,64 e F1-score de 0,52, indicando maior dificuldade na classificação da classe minoritária, resultado consistente com estudos recentes sobre detecção de discurso de ódio em cenários com desbalanceamento de classes (FETAHI et al., 2025).




Figura 1 – Distribuição das classes do conjunto de dados (ódio e não ódio). Fonte: Elaboração Própria

Além da modelagem textual, foram construídas duas abordagens de grafos a partir dos embeddings gerados pelo modelo. A primeira, baseada em limiar de similaridade, resultou em uma estrutura mais densa e altamente conectada, conforme apresentado na Figura 2.




Figura 2 – Grafo construído com base na similaridade semântica entre os textos, utilizando limiar de similaridade para definição das conexões entre os nós. Fonte: Elaboração própria.

Já a segunda, utilizando o método k-Nearest Neighbors (kNN), apresentou uma organização mais equilibrada e agrupamentos semânticos mais definidos entre os textos, como mostrado na Figura 3. Esses resultados indicam que a utilização de embeddings combinada com estruturas em grafos possibilita representar relações contextuais relevantes entre as mensagens, fornecendo uma base consistente para futuras aplicações envolvendo Redes Neurais Gráficas (GNNs).




Figura 4 – Grafo construído utilizando o método k-Nearest Neighbors (kNN), no qual cada nó é conectado aos seus vizinhos mais próximos com base na similaridade entre os embeddings. Fonte: Elaboração própria.

De forma geral, os resultados demonstram que a integração entre técnicas de Processamento de Linguagem Natural e modelagem em grafos apresenta potencial para melhorar a detecção de discurso de ódio em redes sociais (LI et al., 2023). Além disso, o trabalho contribuiu para a construção de um pipeline completo de processamento textual e representação relacional dos dados, estabelecendo uma base sólida para as próximas etapas da pesquisa, incluindo a aplicação de modelos baseados em GNNs e a ampliação do conjunto de dados utilizado. A integração entre embeddings semânticos e estruturas relacionais demonstrou capacidade de representar conexões contextuais entre os textos, aspecto relevante em aplicações recentes de análise estrutural e detecção de padrões em grafos (LI et al., 2023).

### 4.3 Repositório GitHub e vídeo explicativo

O projeto possui um repositório no GitHub para organização e versionamento do desenvolvimento, link: [https://github.com/Piccazzio/Projeto\\_IA/tree/main](https://github.com/Piccazzio/Projeto_IA/tree/main)

Além de um vídeo explicativo de 5 minutos: <https://youtu.be/ksaO45nc5nw>

## 5. Conclusão

Este trabalho apresentou uma abordagem baseada na integração entre técnicas de Processamento de Linguagem Natural e estruturas em grafos para a detecção de discurso de ódio em redes sociais. A proposta teve como objetivo explorar não apenas o conteúdo textual das mensagens, mas também as relações semânticas existentes entre os dados, utilizando modelos baseados em Transformers e futuras aplicações com GNNs (KIPF; WELLING, 2017).

Os resultados obtidos demonstraram que o modelo baseline utilizando o BERTimbau apresentou desempenho satisfatório na tarefa de classificação textual, alcançando acurácia de 83% no conjunto de teste. Além disso, a geração de embeddings e a construção das estruturas em grafos possibilitaram identificar relações contextuais e agrupamentos semânticos relevantes entre os textos, evidenciando o potencial da modelagem relacional para aplicações de detecção de toxicidade e discurso de ódio. Também foram identificados desafios importantes, como o desbalanceamento das classes e indícios de overfitting, aspectos que deverão ser tratados nas próximas etapas da pesquisa.

De forma geral, considera-se que os objetivos propostos para esta etapa do projeto foram alcançados, especialmente no desenvolvimento do pipeline de processamento textual, geração de embeddings e construção das representações em grafos. Como principais contribuições, destacam-se a integração entre técnicas modernas de PLN e modelagem relacional, a utilização de dados reais relacionados a eventos de relevância social e a construção de uma base estruturada para futuras aplicações envolvendo GNNs. Como trabalhos futuros, pretende-se ampliar o conjunto de dados, aprimorar o balanceamento das classes e implementar modelos baseados em Redes Neurais Gráficas, visando aumentar a robustez, a capacidade de generalização e a precisão da detecção de discurso de ódio em ambientes digitais (DUONG; ZHANG; LU, 2022).



## 6. Referências

ABUSAQER, Mahmoud; SAQUER, Jamil; SHATNAWI, Hazim. Efficient Hate Speech Detection: Evaluating 38 Models from Traditional Methods to Transformers. 2025. Disponível em: <https://arxiv.org/pdf/2509.14266> . Acesso em: 28 maio 2026.

AL-SAQQA, Samar; AWAJAN, Arafat; HAMMO, Bassam. A Survey of Hate Speech Detection for Arabic Social Media: Methods and Datasets. *Procedia Computer Science*, v. 251, p. 224–231, 2024. DOI: 10.1016/j.procs.2024.11.104. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050924033386> . Acesso em: 28 maio 2026.

BÖLÜCÜ, Necva; CANBAY, Pelin. Hate Speech and Offensive Content Identification with Graph Convolutional Networks (HASOC). *CEUR Workshop Proceedings*, v. 3159, 2021. Disponível em: <https://ceur-ws.org/Vol-3159/T1-4.pdf> . Acesso em: 28 maio 2026.

BROOK, Joshua Wolfe; MARKOV, Ilia. Leveraging LLMs for Context-Aware Implicit Textual and Multimodal Hate Speech Detection. 2025. Disponível em: <https://arxiv.org/pdf/2510.15685> . Acesso em: 28 maio 2026.

DAS, Susmita; DUTTA, Arpita; ROY, Kingshuk; MONDAL, Abir; MUKHOPADHYAY, Arnab. A Survey on Automatic Online Hate Speech Detection in Low-Resource Languages. 2024. Disponível em: <https://arxiv.org/abs/2411.19017> . Acesso em: 28 maio 2026.

DEVLIN, Jacob; CHANG, Ming-Wei; LEE, Kenton; TOUTANOVA, Kristina. BERT: Pretraining of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT 2019*, p. 4171–4186, 2019. Disponível em: <https://aclanthology.org/N19-1423/> . Acesso em: 28 maio 2026.

DUONG, Charles; ZHANG, Lei; LU, Chang-Tien. HateNet: A Graph Convolutional Network Approach to Hate Speech Detection. *IEEE BigData Workshops*, 2022. Disponível em: <https://people.cs.vt.edu/~clu/Publication/2022/IEEE-BD22-Proceedings-Duong.pdf> . Acesso em: 28 maio 2026.

FETAHI, Endrit; SUSURI, Arsim; HAMITI, Mentor; KASTRATI, Zenun; CANHASI, Ercan; MISINI, Arta. Enhancing Social Media Hate Speech Detection in Low-Resource Languages using transformers and explainable AI. *Social Network Analysis and Mining*, 2025. Disponível em: <https://link.springer.com/article/10.1007/s13278-025-01497-w> . Acesso em: 28 maio 2026.

HEBERT, Liam; CHEN, Hong Yi; COHEN, Robin; GOLAB, Łukasz. Qualitative Analysis of a Graph Transformer Approach to Addressing Hate Speech: Adapting to Dynamically Changing Content. 2023a. Disponível em: <https://arxiv.org/pdf/2301.10871> . Acesso em: 28 maio 2026.

HOQUE, Syed Mohaiminul; RAHMAN, Naimur; HOSSAIN, Md Sakhawat. Gradient Masters at BLP-2025 Task 1: Advancing Low-Resource NLP for Bengali using Ensemble-Based Adversarial Training for Hate Speech Detection. 2025. Disponível em: <https://arxiv.org/pdf/2511.18324> . Acesso em: 28 maio 2026.

KIPF, Thomas N.; WELLING, Max. Semi-Supervised Classification with Graph Convolutional Networks. International Conference on Learning Representations (ICLR), 2017. Disponível em: <https://arxiv.org/abs/1609.02907>. Acesso em: 28 maio 2026.

LI, Jiakang; LAI, Songning; SHUAI, Zhihao; TAN, Yuan; JIA, Yifan; YU, Mianyang; SONG, Zichen; PENG, Xiaokang; XU, Ziyang; NI, Yongxin; QIU, Haifeng; YANG, Jiayu; LIU, Yutong; LU, Yonggang. A Comprehensive Review of Community Detection in Graphs. 2023. Disponível em: <https://arxiv.org/abs/2309.11798> . Acesso em: 28 maio 2026.

LIU, Yinhan; OTT, Myle; GOYAL, Naman; DU, Jingfei; JOSHI, Mandar; CHEN, Danqi; LEVY, Omer; LEWIS, Mike; ZETTLEMOYER, Luke; STOYANOV, Veselin. RoBERTa: A Robustly Optimized BERT Pretraining Approach. 2019. Disponível em: <https://arxiv.org/abs/1907.11692> . Acesso em: 28 maio 2026.

MAJEED, Abdul; RAUF, Ibtisam. Graph theory: A comprehensive survey about graph theory applications in computer science and social networks. Inventions, v. 5, n. 1, p. 10, 2020. Disponível em: <https://www.mdpi.com/2411-5134/5/1/10> . Acesso em: 28 maio 2026.

MIKOLOV, Tomas; CHEN, Kai; CORRADO, Greg; DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. 2013. Disponível em: <https://arxiv.org/abs/1301.3781> . Acesso em: 28 maio 2026.

NIRMAL, Ayushi; BHATTACHARJEE, Amrita; SHETH, Paras; LIU, Huan. Towards Interpretable Hate Speech Detection using Large Language Model-extracted Rationales. 2024. Disponível em: <https://arxiv.org/pdf/2403.12403> . Acesso em: 28 maio 2026.

NOURI, Célia; COINTET, Jean-Philippe; CLAVEL, Chloé. Graphically Speaking: Unmasking Abuse in Social Media with Conversation Insights. ACL 2025. Disponível em: <https://aclanthology.org/2025.acl-long.894.pdf> . Acesso em: 28 maio 2026.

ROSSI, Emanuele; CHAMBERLAIN, Ben; FRASCA, Fabrizio; EYNARD, Davide; MONTI, Federico; BRONSTAIN, Michael. Temporal Graph Networks for Deep Learning on Dynamic Graphs. 2020. Disponível em: <https://arxiv.org/abs/2006.10637> . Acesso em: 28 maio 2026.

VÉLIČKOVIĆ, Petar; CUCURULL, Guillem; CASANOVA, Arantxa; ROMERO, Adriana; LIÒ, Pietro; BENGIO, Yoshua. Graph Attention Networks. International Conference on Learning Representations (ICLR), 2018. Disponível em: <https://arxiv.org/abs/1710.10903> . Acesso em: 28 maio 2026.

XENOS, Alexandros; PAVLOPOULOS, John; ANDROUTSOPOULOS, Ion; DIXON, Lucas; SORENSEN, Jeffrey; LAUGIER, Léo. Toxicity Detection Sensitive to Conversational Context. First Monday, 2022. Disponível em: [https://www.researchgate.net/publication/363286762\\_Toxicity\\_detection\\_sensitive\\_to\\_conversational\\_context](https://www.researchgate.net/publication/363286762_Toxicity_detection_sensitive_to_conversational_context) . Acesso em: 28 maio 2026.